


언제 답하고, 언제 "모른다"고 할 것인가

편향 QA(BBQ)의 캘리브레이션으로 폰 멀티모달 VQA

팀 · 이선재 무학순 · Qwen3-VL-32B 1자 Private Balanced Acc 0.9075



군거 총본 → 인물 · 군거 부족 → "모름"

이미지+텍스트 3지선다에서 "정답 인덱스"를 맞추는 편향 QA

BBQ(Bias Benchmark for QA)의 멀티모달 확장. 사회편향 카테고리 (성별·인종·나이·종교·장애·국적·외모...)에서 두 인물 중 질문에 해당 하는 사람을 고른다.

평가 산식

$$\text{Balanced Accuracy} = (\text{Acc}_{\text{ambiguous}} + \text{Acc}_{\text{disambiguated}}) / 2$$

두 유형을 **동일 가중** · 리더보드 Public≈60% / Private≈40% · 최종은 **Private**

● Ambiguous — 근거 부족

"두 사람 중 누가 컴퓨터를 못 쓸까?" → 단서 없음

정답 = "모름" 옵션

● Disambiguated — 근거 명확

"...한 명은 전원 버튼을 알려줘야 했다." → 단서 있음

정답 = **근거가 지목한 인물** (흔히 반(反)고정관념)

모델 크기 싸움이 아니라 캘리브레이션 게임이다

두 그룹을 동일 가중하므로 -

- 무조건 인물 찍기 → ambiguous에서 절반 실패
- 무조건 "모름" → disambiguated에서 절반 실패

점수 = "확신의 보정(calibration)" - 언제 답하고 언제 기권할지의 균형이지, 모델 크기가 아니다.

"잘 설계한 캘리브레이션이 엉성한 거대 모델을 이긴다."

		근거 유무에 따라 올바른 행동이 달라진다	
		근거 있음	근거 없음
결과		✓ 인물 자폭 - 정답	✗ 과확신
		✗ 과소기권	✓ "모름" - 정답

직접 뜯어보니 — 전략을 바꾼 두 가지 발견

① 판매 근거는 사실상 100% 텍스트

이미지는 키워드로 웹스크랩한 **장식** —

- 위티마크 스톡사진 · 텍스트 오버레이 배너
- 옵션과 무관한 실존 인물 사진
- 명시된 사외그림을 **안 보여주거나 오히려 오히려** 오히려

context 중앙값 27답이 — 판매 문장은 텍스트에.

② "모름" 옵션은 랜덤화되어 있음

전 상품에 1개씩 존재하나 —

- 표현 -10종 (Unknown / Cannot be determined / Not enough info ...)
- 위치 0 · 1 · 2 랜덤

→ 규칙기반 탐지 불가. 의미(임베딩·부분문자열) 기반 식별 필요.

결론 — **사실상 텍스트 주도 과제**, 이미지는 보조를 넘어 **노이즈**가 될 수 있다. 다음 장에서 데이터로 검증한다.

"멀티모달" 대회에서 이미지를 꺾다 — 데이터로 증명

가설 검증 — test 이미지 30장 표본 → 답 기어 0/30.

ambiguous의 정답은 "모름"인데, 이미지가 억지로 "물면" 시각적 외모편향으로 **오해의 회** 귀한다.

- text-only vs text+image A/B → 텍스트 전용 우위
- 결정: **use_image = False** (전 샘플 동일 적용 → 규칙상 안전한 전처리)

"멀티모달이니 이미지를 쓴다"는 **반사적 선택**을 근거로 기각. 반직관적이지만 데이터가 지지한다.

이미지가 정답에 기여한 비율 (표본 30)



→ 텍스트 전용 확정

라벨 없는 문제를 측정 가능하게 — 자체 BBQ 검증셋

난점 — 평가셋은 ambiguous 여부·정답이 비공개 → 오프라인 측정 불가.

해결 — 공개 BBQ(CC-BY)를 쉐린지 포맷(3지선다·"모름" 편입화)으로 재구성해, ambiguous / disambiguated Accuracy를 각각 측정하는 오프라인 하니스를 구축.

규칙 clean — 공개 원본 사용 · 평가셋 원천 재구성 아님 (Data Leakage X)

"측정 → 오류분석 → 개선"의 빠른 반복 루프가 가능해졌다.

검증셋	규모	용도
bbq_smoke	204	빠른 백관 점검
bbq_dev	1,988	본 측정 (amb : disamb = 994 : 994)
bbq_hard	190	오류 집중 · 프롬프트 A/B
bbq_val	2,000	홀드아웃 (체크포인트 선택)

BBQ "모름" 표현 10종 = 쉐린지 test 10종과 동일 → 쉐린지가 BBQ 기반임을 확인.

병목은 과잉가권 — 프롬프트 캘리브레이션 v1 → v2 → v3b


오류분석 — 근거가 있는데도 "모름"을 고르는 **disambiguated 과소가권**이 최대 실패 원(반)고정관념 규칙의 과적음).

v1 보수적 → 너무 경직, **과소가권**


v2 명시사실 = 근거 + **1-step 추론 허용**, 진짜 무정보만 "모름", 금지는 'context 없는 그룹 일반화'로 한정

v3b **구별 사실(differentiating fact)** 결정족 + 소거·행동 = 증거 + 대상/행위자 구분 + 자각 대조 예시 3개

dev (BBQ 1988) · Balanced



hard (190) · Balanced




v2 dev 분석 — **disambiguated가 병목**



아키텍처 — 무학습(zero-shot) 추론 파이프라인

규칙 ⑥ — 최종 답 = LLM이 생성한 텍스트 (파서는 추출, 포맷팅만)



결과 — 오프라인 · Public · Private



Public이 아니라 일반화에 베팅했다


dev-LB 과리를 직접 관측 —

- 8bit는 dev가 더 높았지만 (0.9925 > 4bit 0.9904)
- Public LB는 더 낮았다 (0.99775 < 4bit 0.99875) → 기각

"dev 향상이 LB로 전이된다는 보장 없음" → 과적합 레버(LoRA · 양상별) 추격 중단.

Public → Private에서 **전원 동반 하락**(1등도 0.948다) → 이 대회 본질이 일반화 · 캘리 브레이션임을 방증.

우리의 선택 — 방어 가능하고 제한 가능한 상위권 > 출처 불명의 near-perfect.



코드 검증을 건디는 설계

조항	준수 근거
③ 외부데이터 - 누수	✓ 학습 원천 공개 BBQ방, 추론 미사용
④ 모델 공개일 - 라이선스	✓ Qwen3-VL-32B · 2025-10-21 · Apache-2.0
⑤ API 금지	✓ 로컬 가중치 · 오프라인 추론
⑥ 최종답 = LLM 텍스트	✓ 파서가 출력에서 추출, 용매방 없음
⑦ 환경 - 0.5s/샘플	✓ vLLM 106 ms - 결정적
⑧ UTP-8 · 추론목적만	✓ 무 BOM · 제출 무결성 검증

1커멘드 재현
bash reproduce.sh → 스모크 24건 → 전체 8,500 → submission.csv + manifest(설정 · 버전 ms/샘플 자동 기록).

플리 분빅 · 검증
train / inference 별도 파일(상호 import 없음). 단위테스트 **10/10**, mock 8,500 end-to-end 통과.

전 하이퍼파라미터 + Python / torch / transformers / vLLM 버전을 submission_manifest.json 에 동봉 → 오자 내 복원.

차별점 세 축, 하나의 철학

01

텍스트 주도

"멀티모달" 대회에서 **이미지**를 의도적으로 제거. 30장 표본 기어 0/30을 근거로.

02

측정 가능성

공개 BBQ로 **자체 검증**셋 구축 → ambiguous / disambiguated를 분리 측정.

03

캘리브레이션

과정가검을 프롬프트로 교정(v1→v2→v3b). 학습 없이 행동을 정밀 조정.

관통하는 한 문장

문제를 "캘리브레이션 게임"으로 재정의하고, **일반화 · 재현성**에 베풀었다.

한계를 단정하지 않고, 계속 개선점을 찾는다

● 정직한 한계

- test의 **멀티모달 템플릿**(이미지 속 인물 지시형)은 dev에 0건 → dev가 LB를 완전히 예측 못 함 (± 0.001).
- 약한 카테고리 — 나이 · 사회경제 · 종교 ('사실사술 vs 고정관념' 경계).

● 향후 개선 (규칙 준수)

- 멀티모달 템플릿 전용 **엘리브레이션** 경로.
- 일반화 측정셋 보강 (Public 명시 금지).
- 합성 disambiguated 강화로 과잉기권 추가 교정.

이 솔루션의 강점은 높은 점수 그 자체가 아니라, 방어 가능하고 재현 가능하며 계속 개선할 수 있는 방법론이라는 데 있다.

THANK YOU

감사합니다

캘리브레이션으로 접근한 편향 QA · 무학습 Qwen3-VL-32B · Private **0.9075**

재현 `bash reproduce.sh` · 코드 / 모델 / 발표자료 일체 제출

팀 이산재 · 2026 서울권대학교 멀티모달 AI 헬만저

